

Grimmer, J. et al. 2022 / Ch.17-18

17 教師あり学習の概要

教師あり学習は、人間があらかじめ文章に正解のラベルを付けて、それをガイドに文書に基づくラベルを推定できる統計的モデル(分類器)を構築する手法となっている。分類器をラベルなしの文書に適用することで、それらの文書を分類することができる。本章は、トレーニングデータの作成、モデルの学習、予測結果の検証を含む教師あり学習の一連プロセスについて紹介する。

教師あり学習の目的は、文書の特徴と研究者が事前に定義するカテゴリまたは概念を対応つけることである。具体的に言えば、教師あり学習は以下の式で表す:

$$y_i = f_{\mu}(W_i) \quad (1)$$

- y_i : 文書 i に対する予測
- W_i : 文書 i の特徴量
- μ : 予測モデルのパラメタ

パラメタ μ は、一部の $\mathbf{W}$ と $\mathbf{y}$ に基づく学習を通じて推定される。そこで、研究者のタスクは三つがある:

1. ラベル付け: 文書とラベルの推定関係を熟考する。
2. 特徴量抽出: 人間が使っている自然言語が持つ意味をコンピュータで解析するため、自然言語から有用の特徴量を抽出し、コンピュータが処理できる数値表現に変換することを指す。具体的には, word counting, tf-idf, 単語埋め込みなどの手法が挙げられる。多くの場合、適切な特徴量抽出は推定モデルより重要だと考えられる。
3. 推定モデルの構築: 推定モデルによって、"どうやって" 文書の特徴からラベルを推定することも異なっている。

例えば、Word Frequency Counter と RNN は異なる視点でテキストを分析している。

- **Word Frequency Counter:** 比較的に単純な考え方は、テキストにおけるどのような単語は出現することでラベルを予測する。つまり、ある文書を単語の集合とそれぞれの単語の頻度情報に変換する。ここでは、単語の順番や位置についての情報はすべて捨象されていることに注意しよう。
- **RNN:** 単語の分散表現となるベクトルが逐次的にインプットされるため、バグオブワーズアプローチとは異なり、時系列構造をもったシーケンスデータがインプットデータとなる。具体的には、 T 個の単語の埋め込み表現が逐次的に処理されていく。それぞれの t 時点でアウトプット y_t とともに隠れ状態 h_t が更新されるが、このとき、前の h_{t-1} も入力として受け取る。このことによって、過去の自分の状態を「記憶」することが可能なり、時系列構造をもったデータを適切に処理できるようになるのである。




Figure 1: RNN

17.1 例: 言説的ガバナンス

本章はGillion (2016) を例として教師あり分類について説明する。Gillion (2016) によると、言説は選挙や政策だけでなく、民衆と政策立案者がどのような議題を設定し、政策を設計、議論、実施と評価することも大きな影響を与えている。特に、人種に関する言説が少ない場合、有権者は人種不平等に対する注目度が低くになって、政策立案における人種不平等に対する配慮も足りなくなることが想定されている。

Gillion (2016) は大統領と議員のスピーチ、ラジオ記録など大量的な言説データを集めた。人種に関する言説の影響を検証するため、まず人種に関する言説を特定する必要がある。そこで、教師あり分類の手法が用いられた。

17.2 教師データの作成

教師データに「人種に関する言説である」または「人種に関する言説ではない」のラベルを付与する。

- 教師データの代表性を保つため、年代に基づく層化抽出でテキスト抽出した ($N = 12,300$)。
- 教師データの精度を確保するため、コーダー間のコミュニケーションは不可欠である。また、ラベル付けの一致性の検証も必要される。¹

17.3 教師あり学習による分類

教師データに「人種に関する言説である」または「人種に関する言説ではない」のラベルを付与する。

- 特徴量の抽出: 今回の論文は句読点、数字、スペース、ストップワードを除外する上で、バグオブワーズで文書の分散表現を構築した。
- 推定モデルの選定: 多くの機械学習・深層学習モデルが適用可能である。この論文は、アンサンブル・ラーニングという手法を用いた。つまり、さまざまな学習アルゴリズムの予測結果をまとめて、多数決で最適の結果を決める²。

17.4 分類結果の検証

- 交差検証: 教師データを分割し、その一部をまず学習して、残る部分でその学習したモデルのテストを行い、学習の妥当性の検証・確認する。検証の一般性を確保するため、教師データの分割から始まる一連の操作を複数回繰り返して平均を取る。よく使われるのは k -分割交差検証である³(Figure 2)。
- 検証指標: 精度は必ず最適の指標ではない。そのほか、Recall や F1-score などの指標も併せて検証すべきである。この論文は、大統領の言説に対する 0.77, 議会の言説に対する 0.66 の精度を達成した⁴。

¹Cohen's Kappa や Fleiss Kappa は一貫性の指標としてよく使われる。

²現在、様々なモデルが事前に実装されて、効率的にアンサンブル・ラーニングを実行できるライブラリーは多くある。例えば、[nni](#)や[autogluon](#)。

³標本群を k 個に分割する。そして、そのうちの 1 個をテスト事例、残る $k-1$ 個を訓練事例として、推定値を得る。同様に、 k 個に分割された標本群のそれぞれが 1 回ずつテスト事例となるよう、計 k 回、推定値を計算する。

⁴実に、この論文は以下の作業で精度を改善した: Two research assistants read all of the computer classified statements that were identified as dealing with race and reclassified those statements into their correct category ([GILLION, 2016](#)).




Figure 2: k-分割交差検証

17.5 分析結果

- 人種に関する言説の時系列変化 (Figure 3)。
- 人種に関する言説の地理的分布 (Figure 4)。




Figure 3: The rise and fall of a discourse on race in the Oval Office.




Figure 4: Location of congressional districts with representatives who often discuss race on the House floor (2002-2012).

コメント

- 実践的な観点から言えば、自然言語処理のタスクは基本的に転移学習で行われる。具体的には、まず (1) 事前学習で、大規模のテキストとデータを用いて共通な汎用的な特徴量を学習する (e.g., GPT, XLNet, BERT)。その後、少量のラベル付きデータセットでモデルを (2) ファインチューニングすることで、高精度な性能を達成することができる。一般的には、ファインチューニングにおける複雑なモデルを追加する必要はない。
- 本章の本文部分にはあんまり触れていないが、実際にこの論文の手法で構築した分類器は信頼性が高い分析に資する結果を得られない。結局、人間の作業を追加することで予測結果を改善した。社会科学の研究にとって、精度が高い分類器を作ることではなく、精度が高い結果を得ることは目的になるので、場合による人間の手作業と計算的方法を組み合わせることもあり得る。

18 教師データをコーディングする

ヒューマンコーディングは、一定なルールに従ってテキストを特定なカテゴリに割り当てるプロセスである。このプロセスは、コードブック、コーダーに対する訓練、およびコーダーが作業する際内的思考の組み合わせである。

ヒューマンコーディングは、自動化された分類よりもはるかに時間がかかりますが、関心のあるカテゴリーを明確にし、その分類がどのように行われるかを明らかにするのに有用である。

一見簡単そうに見えるかもしれないが、言語の曖昧さ、コーダーの注意力の欠如、微妙な概念の違いなどにより、専門家であっても信頼性の高いコーディングは困難である。残念ながら、社会科学分野における、専門家コーダーのチームはほとんど存在しない。また、言語には文脈に深く関わる性質があるため、コードブック全体をあらかじめ指定することも難しい。

理想的なやり方として、最初の段階は予備的で簡潔なコードブックを作成し、一部のテキストに適用することで、コーディングスキームの曖昧さやカテゴリの見落としを発見する作業が推奨される。コードブックの修正し、コーディングの曖昧さが十分に解消されるから、別のテキストに適用する。

本章では、まず、コードブックの作成、コーダーの選択、および教師データのコーディングについて説明する。次に、クラウドソーシングや既存データの活用などコーディング方法も紹介する。

18.1 良い教師データの特徴

ヒューマン・コーディングの目的は、テキストからカテゴリへの信頼性の高いマッピングを提供することである。良い教師データでは、次のような特徴が挙げられる：

- **Objectivity-Intersubjectivity:** カテゴリへの理解は完全的な客観的なものになれないが、少なくとも研究者の間にある程度に共通の認識を達成すべきである。
- **An A Priori Design:** カテゴリを定義と再定義することは、研究プロセスの重要な部分である。特に、ヒューマンコーディングにおける、カテゴリはさらに洗練される必要があるかもしれない。ただ、最終的な教師データは、最終的なコードブックに基づき、新しいデータでコーディングされる必要があります。
- **Reliability:** 異なるコーダーが独立に作業しても、同じような結果が得られる。
- **Validity:** 測定は、関心のある概念やカテゴリーを反映したものでなければならない。
- **Generalizability:** 教師データを作成する際は、データの一部に対する作業を行う。そのため、データセット全体や最終的な対象者に対して一般化できることに注意すべ

きである。

- **Replicability:** 測定は同じデータで再現でき、さらに異なるデータや異なるコンテキストでも再現できることが望ましい。

18.2 ハードコーディング

コーディングには、いくつかのステップと配慮点が挙げられる。

18.2.1 コードブックを決める

コードブックは、コーダーがテキストをカテゴリーに分類するための説明書である。独自のカテゴリーを作る際、研究者自身がそれを応じてコードブックをコードブックを書かなければならない。コードブックは、関心のあるカテゴリーを定義するだけでなく、信頼性、妥当性、再現性を確保するために、コードに研究者の意図を効果的に伝える必要がある。よくあるのは、コードブックで各カテゴリーの例文や特殊な例を提示することである。また、フローチャートはカテゴリーの階層構造の理解と複数のカテゴリーへの対応にも役に立っている。

研究の目的に合致するような既存のコードブックを活用することも推奨される。例えば、[Comparative Manifestos Project](#)は選挙マニフェストの政策選好を分類するためのコードブックをいくつか提供している。

per104	Military: Positive The importance of external security and defence. May include statements concerning: • The need to maintain or increase military expenditure; • The need to secure adequate manpower in the military; • The need to modernise armed forces and improve military strength; • The need for rearmament and self-defence; • The need to keep military treaty obligations.
--------	---

Figure 5: Codebook of Comparative Manifestos Project

18.2.2 コーダーを決める

基本的には、研究者自身ではなく、コーダーがテキストにラベルを貼り付けることになる。コードブックの信頼性を測定するため、少なくとも二人のコーダーが必要される。研究分野で多くの経験を積んだコーダーなら、二人でも十分であるが、そうではない場合、コーディングのミスが発生する可能性を配慮し、多くの検証を行う必要があるかもしれない。




Figure 6: Accuracy with Constant Number of Total Codings. *The informational gains from increasing the number of documents coded are greater than from increasing the number of codings of a given document. This does not obviate the need to have multiple coders code at least a subset of documents, namely to determine coder quality and to select the best set of coders to use for the task at hand. But once the better coders are identified, the optimal strategy is to proceed with one coder per document (BARBERÁ et al., 2021).*

18.2.3 テキストを決める

次に、どの文書を何件コーディングするかを決める必要がある。分類器の汎化性と高いパフォーマンスを達成するためには、教師データの代表性を確保することは重要である。1つの簡単な方法は、大規模なデータセットから単純な無作為抽出を行うことである。必要される教師データの数は、カテゴリの数とコーダーの信頼性に依存する。カテゴリ数が多いほど、またコーダーの信頼性が低いほど、信頼性の高い分類器を作成するために必要なテキスト数が多くなる。分類器の精度を検証することで、十分な数のテキストがコーディングされているかどうかを検証することができる。

18.2.4 コーダーを管理する

研究者はコーダーを訓練してからコーディング作業を始めさせる。

- コードブックををよく読ませ、疑問点を洗い出す。

- サンプルテキストでのコーディング作業を通じて理解度を確認する。
- コーディングに関する指示を修正する必要があるかどうかを検討する。

コーダーに対してトレーニングとコードブックが完成したら、コーダーはお互いに交流せず、コードブック以外のリソースと接触しない状況で作業を進めべきである。

18.2.5 信頼性を検証する

Cohen's Kappa や Krippendorff's Kappa はコーディングの信頼性を検証するための指標としてよく使われる。

カッパ係数は以下のように計算する。

$$k = \frac{p_0 - p_e}{1 - p_e} \quad (2)$$

$$p_e = \frac{1}{N^2} \sum_k n_{k1} n_{k2} \quad (3)$$

- p_0 は実際に一致している評価の割合
- p_e は一致する評価の期待値を割合で表したものである。つまり k 番目のカテゴリと判断した評価の数を評価者 1 と 2 それぞれの合計を求め掛け合わせ和を計算する。和をサンプルサイズ N の 2 乗で割ると算出される。

18.2.6 ドリフトを統制する

- コーダーがコーディング作業を進むにつれて、疲労や新たな洞察が得られたため、カテゴリにラベルを割り当てる方法を変更する可能性がある。このようなドリフトを統制するためには、コーディングプロセスの複数の時点で信頼性を評価することが推奨される。
- データが更新または追加されたら、コードブックに新たな曖昧さが生じる場合がある。コードブックがドリフトに基づいてアップデートされた場合、新しいデータに違いラベルが付けられる可能性がある。このようなドリフトを統制するためには、新しい基準に基づく改めてコーディングを行うことが望ましい。

18.2.7 例:MAKING THE NEWS

ニュース議題の設定について、[Boydston \(2013\)](#) は、メディアが多くの事件・話題を観測しているが、世の中に注目される事件・話題だけ報道として取り上げられることを論じて

いる。この仮説を検証するために、[Boydston \(2013\)](#) は *New York Times* の第一面に載せた 31,034 ニュースを取得し、政策争点によって分類した。

- 既存のコードブック *Policy Agendas Project* に基づいて、*New York Times* のコーパスの特徴に応じて注釈を付けた。最終的には、27 の主要なトピックカテゴリと、その中の 225 のサブトピックから構成されている。
- サンプルに対するコーディングで高い信頼性を確認してから全体のテキストに対するコーディング作業に進める。Cohen's Kappa と Krippendorff's Kappa でコーディングの信頼性を報告した。

18.3 クラウドソーシング

近年、*Mechanical Turk* のようなクラウドソーシングの導入により、注釈者、調査回答者、実験参加者の募集の仕方が大きく変わった。オンライン労働市場を通じて大規模な労働力を雇用できることが期待されているが、常時にオンライン労働市場の労働者はそれほど多くない、さらに、これらの労働者は特定な社会・政治的属性に偏る傾向がある。

クラウドソーシングを利用する際、クラウドソーシングとヒューマンコーディングの違いを念頭に置いておきたい。

- クラウドソーシングを利用する際、集中的なトレーニングを行うことが難しくなる。そのため、クラウドワーカーに任せられる仕事は、専門的な知識を必要としない比較的単純なものに限られる。
- クラウドワーカーの数を迅速に増やすことは可能である。大学や企業では、新しい労働者を雇用するのに時間がかかるが、クラウドソーシングでは、数時間で何千ものアノテーションを完成することができる。
- アノテーションにエラーが発生する可能性を配慮する必要がある。クラウドソーシングでは、少人数のヒューマンコーディングと同じように、エラー率が許容範囲内に収まるまでトレーニングを続けることは難しいので、新しい方法が求められている。この点については、20 章でまた紹介される。
- クラウドソーシングの方が安価である。ただ、適切な報酬に関する倫理的な配慮が必要である。

クラウドソーシングを利用する際、研究者はコーディングタスクをより単純なタスクに転換することは多い。例えば、スケーリングではなく二つのテキストを比較することを通じてテキスト进行分类するアプローチがあげられる。

[CARLSON and MONTGOMERY \(2017\)](#) によると、絶対的な尺度を正確に割り当てるよりも、ペアワイズ判定を行うために必要なトレーニングがかなり少ない。




Figure 7: Discussion of defense in front page news articles in *The New York Times* increased substantially after September 11, 2001

18.4 既存データを活用する

既存データがカテゴリとラベル付けの材料に資することができる。

例えば、Nielsen (2017) はなぜ一部のイスラム教聖職者が暴力的なジハードへの支持を表明のかを明らかにしたい。そのために、どのくらい暴力的なジハードに支持することを測る「ジハードスコア」というラベルを付与する必要がある。彼は "*The Jihadist's Bookbag*"




Figure 8: A figure explaining how pairwise comparison tasks can be more tractable than absolute scale tasks. Task C is going to be much more consistent than either task A or B.

というジハード主義のイデオロギーを紹介する既存の材料を活用し、効率的にスコアを付与する作業を完成できた。

Appendix

コーディングの信頼性 (MIKHAYLOV; LAVER; BENOIT, 2012)

- コーディングの信頼性と精度を向上させるため、検証、トレーニングおよびコードブックの修正を重ねなければならない。Figure 9 は、トレーニングとコードブックの修正を通じてコーディングの一致性が高くなることを示した。
- コーディングは非常に複雑な作業であり、たとえ既に広く使われるデータでも誤った場合がある。例えば、Comparative Manifestos Projectでは、一つのテキストは一人のコーダーより一回しかコーディングされていないので、誤りが生じる可能性が高いと指摘される。
- クラウドソーシングを通じてより多くのコーダーを雇用できるが、誤りがよく生じる。Figure 10 が示したように、クラウドワーカーと専門家によるコーディングの結果の一致率は高いと言えないだろう。

Table 1 Coder reliability test results reported by CMP

<i>Test description</i>	<i>Mean correlation</i>	<i>N</i>	<i>Reference</i>
Training coders' solutions with master	0.72	39	Volkens (2001a, 39)
Training coders' second attempt with master	0.88	9	MPP2 (Klingemann et al. 2006, 107)
All pairs of coders	0.71	39	Volkens (2001a, 39)
Coders trained on second edition of manual	0.83	23	Volkens (2007, 118)
First time coders	0.82	14	Volkens (2007, 118)
First test of coders taking second contract	0.70	9	Volkens (2007, 118)
Second test of coders taking second contract	0.85	9	Volkens (2007, 118)

Figure 9: Pearson' s R for the aggregate percentage measured across 56 coding categories for the test document




Figure 10: Summary of coder reliabilities compared to Master. The dashed line indicates the conventional lower bound as to what is considered reliable in interpretations of Cohen's k

Active Learning によるサンプルテキストの選出 (MILLER; LINDER; MEBANE, 2020)

1. 一部のデータをコーディングする。
2. 一部のデータでラベル y を予測するモデルを学習する。
3. 学習したモデルを用いて残るのテキストに対して予測を行い、予測確率を計算する。
4. 予測確率が一番低いテキストを追加の教師データとして選出する。
5. 十分の教師データを得るまで以上のステップを繰り返す。




Figure 11: F1-score for experiments. The panel columns correspond to the datasets and the rows to the different levels of class imbalance.

References

- BARBERÁ, Pablo et al. Automated Text Classification of News Articles: A Practical Guide. **Political Analysis**, Cambridge University Press, v. 29, n. 1, p. 19–42, 2021. DOI: [10.1017/pan.2020.8](https://doi.org/10.1017/pan.2020.8).
- BOYDSTUN, A.E. **Making the News: Politics, the Media, and Agenda Setting**. [S.l.]: University of Chicago Press, 2013. ISBN 9780226065601.
- CARLSON, DAVID; MONTGOMERY, JACOB M. A Pairwise Comparison Framework for Fast, Flexible, and Reliable Human Coding of Political Texts. **American Political Science Review**, Cambridge University Press, v. 111, n. 4, p. 835–843, 2017. DOI: [10.1017/S0003055417000302](https://doi.org/10.1017/S0003055417000302).

GILLION, Daniel Q. **Governing with Words: The Political Dialogue on Race, Public Policy, and Inequality in America**. [S.l.]: Cambridge University Press, 2016. DOI: [10.1017/CB09781316412299](https://doi.org/10.1017/CB09781316412299).

MIKHAYLOV, Slava; LAVER, Michael; BENOIT, Kenneth R. Coder Reliability and Misclassification in the Human Coding of Party Manifestos. **Political Analysis**, Cambridge University Press, v. 20, n. 1, p. 78–91, 2012. DOI: [10.1093/pan/mpr047](https://doi.org/10.1093/pan/mpr047).

MILLER, Blake; LINDER, Fridolin; MEBANE, Walter R. Active Learning Approaches for Labeling Text: Review and Assessment of the Performance of Active Learning Approaches. **Political Analysis**, Cambridge University Press, v. 28, n. 4, p. 532–551, 2020. DOI: [10.1017/pan.2020.4](https://doi.org/10.1017/pan.2020.4).

NIELSEN, Richard A. **Deadly Clerics: Blocked Ambition and the Paths to Jihad**. [S.l.]: Cambridge University Press, 2017. (Cambridge Studies in Comparative Politics). DOI: [10.1017/9781108241700](https://doi.org/10.1017/9781108241700).